Universidade do Minho
Mestrado em Engenharia Informática
Especialização em Sistemas de data Warehousing

Unidade Curricular de Sistemas de Extração, Transformação e Carregamento de Dados

Ano Letivo de 2025/2026
2º Semestre

TP1

Filipe Abreu Mendes Fernandes Pg61520
Guilherme Pinto Pinho Pg60263
João Pedro Ribeiro Lopes da Silva Pg59966
Paulo Alexandre Rodrigues Alves Pg61537

Março, 2026

SETCD

Data da Receção	
Responsável	
Avaliação	
Observações	

TP1

Filipe Abreu Mendes Fernandes Pg61520
Guilherme Pinto Pinho Pg60263
João Pedro Ribeiro Lopes da Silva Pg59966
Paulo Alexandre Rodrigues Alves Pg61537

Março, 2026

Resumo

O presente trabalho foi desenvolvido no âmbito da unidade curricular de Sistemas de Extração, Transformação e Integração de Dados e tem como objetivo a conceção e modelação de um agente de recolha de dados para uma plataforma de agregação de informação clínica, destinada a integrar dados provenientes de unidades de saúde públicas e privadas. A plataforma tem como finalidade prover de dados um data warehouse de suporte à análise de indicadores de saúde e ao acompanhamento longitudinal de doentes.

O agente concebido integra duas fontes de dados heterogéneas: uma base de dados relacional, que suporta o sistema de informação clínica atualmente em uso pelas unidades de saúde públicas e privadas, contendo registos recentes e estruturados de episódios, consultas, diagnósticos, prescrições e internamentos, e um conjunto de ficheiros em formato CSV, enviados diariamente por laboratórios externos que não se encontram integrados no sistema central, contendo resultados de análises clínicas como hemogramas, bioquímica e microbiologia. A heterogeneidade entre as duas fontes, em termos de formatos de dados, unidades de medida, nomenclatura de parâmetros e identificadores de doentes constitui o principal desafio do agente, exigindo processos robustos de conciliação, desduplicação e normalização antes do carregamento na staging area.

O trabalho documenta de forma estruturada todas as fases do processo: extração, conciliação, preparação, carregamento e controlo de operações, incluindo o tratamento de erros, o registo de logs, o controlo de qualidade e a eventual quarentena de dados. O processo é representado graficamente através de um diagrama BPMN, que ilustra o fluxo de execução do agente, os pontos de decisão críticos e os mecanismos de tratamento de erros. O resultado final é um modelo completo e documentado do agente de recolha, pronto a servir de base para uma eventual implementação futura.

Área de Aplicação: Sistemas de Extração, Transformação e Integração de Dados;

Palavras-Chave: Agente de Recolha, Data Warehouse, Integração de Dados, Saúde, BPMN, ETL, Conciliação de Dados.

Índice

1. Introdução . . . 1
1.1. Contextualização . . . 1
1.2. Apresentação do Caso de Estudo . . . 1
1.3. Motivação e Objetivos . . . 1

2. Agente de angariação de dados . . . 2
2.1. Definição de Agente . . . 2
2.2. Objetivos . . . 2

3. Identificação das fontes de informação . . . 3
3.1. Base de dados relacional . . . 3
3.2. Ficheiros CSV . . . 3

4. Requisitos de Recolha de Dados . . . 5
4.1. Dados a extrair . . . 5
4.1.1. Extração da Base de Dados Relacional . . . 5
4.1.2. Extração dos Ficheiros CSV . . . 5
4.2. Frequência de recolha . . . 5
4.3. Volume de dados . . . 5
4.4. Condições de acesso . . . 6

5. Conciliação e Preparação de Dados . . . 7
5.1. Identificação de Correspondências . . . 7
5.2. Validação dos Dados . . . 7
5.3. Resolução de Conflitos . . . 8
5.4. Limpeza dos Dados . . . 8

6. Preparação e Organização dos Dados . . . 9
6.1. Preparação das tabelas (Utentes, Consultas e Analises) . . . 9
6.2. Transformações . . . 9
6.3. Cálculos derivados . . . 10

7. Carregamento na Staging Area . . . 11
7.1. Definição de staging area . . . 11
7.2. Processo de carregamento . . . 11

8. Controlo de Qualidade e Registo . . . 12
8.1. Controlo de qualidade . . . 12
8.2. Tratamento de erros . . . 12
8.3. Registo (logging) . . . 12

9. Estruturação do Fluxo de Operações . . . 13
9.1. Sequência do Processo . . . 13
9.2. Eventos . . . 13
9.3. Decisões . . . 14

10. Modelação em BPMN . . . 15

11. Conclusões e Trabalho Futuro . . . 20

Referências . . . 21

Lista de Siglas e Acrónimos . . . 22

Índice de Figuras

Figura 1 Diagrama Conceptual BD 3
Figura 2 CSV - hemograma_2026-03-18 4
Figura 3 CSV - bioquimica_2026-03-18 4
Figura 4 CSV - microbiologia_2026-03-18 4
Figura 5 Diagrama BPMN - Agente Angariação de dados 15
Figura 6 Diagrama BPMN - Copiar dados para a DSA 15
Figura 7 Diagrama BPMN - Dados Utentes 16
Figura 8 Diagrama BPMN - Dados Consultas 16
Figura 9 Diagrama BPMN - Dados Análises 17
Figura 10 Diagrama BPMN - Dados para o destino 17
Figura 11 Diagrama BPMN - Analises novas 18
Figura 12 Diagrama BPMN - Analises atualizadas 18
Figura 13 Diagrama BPMN - Analises removidas 19

Índice de Tabelas

Tabela 1 Informação relativa aos ficheiros CSV 4
Tabela 2 Mapeamento de atributos entre fontes para a staging area 9

1. Introdução

1.1. Contextualização

Os sistemas de saúde modernos produzem diariamente volumes consideráveis de informação clínica, distribuída por múltiplas unidades de saúde públicas e privadas. Embora já existam sistemas que unifiquem essa informação, sente-se ainda a necessidade de criar agentes de recolha com o objetivo de consolidar dados provenientes de fontes heterogéneas, especialmente em contextos onde essa integração não se encontra estabelecida. Nesses contextos, cada instituição possui os seus próprios sistemas de informação, formatos de registo e sistemas de codificação clínica, o que se reflete na forma como cada unidade de saúde regista diagnósticos, procedimentos e resultados. Esta fragmentação dificulta a obtenção de uma visão integrada e longitudinal do estado de saúde dos doentes, bem como a produção de indicadores agregados de desempenho assistencial. Neste contexto, a adoção de processos estruturados de extração, transformação e integração de dados assume especial relevância, constituindo a base para a construção de sistemas de suporte à decisão clínica e à gestão do sistema de saúde. Um desafio adicional prende-se com a necessidade de integrar dados clínicos estruturados, provenientes do sistema de informação central, com resultados de análises clínicas enviados por laboratórios externos que não se encontram integrados nesse sistema. A integração destas duas realidades exige mecanismos robustos de conciliação, desduplicação e normalização, sem os quais a qualidade da informação disponibilizada para análise fica comprometida.

1.2. Apresentação do Caso de Estudo

O presente trabalho tem como caso de estudo a conceção e modelação de um agente de angariação de dados para uma plataforma de agregação de informação clínica, destinada a integrar dados provenientes de unidades de saúde públicas e privadas. A plataforma tem como finalidade alimentar um Data Warehouse que suporta a análise de indicadores de saúde e o acompanhamento longitudinal de doentes, nomeadamente ao nível de episódios de internamento, consultas, diagnósticos, prescrições, evolução clínica e cuidados clínicos.a O agente de recolha é responsável por integrar duas fontes de dados distintas: uma **base de dados relacional** que suporta o sistema de informação clínica atualmente em uso, com registos recentes e estruturados de episódios, consultas, diagnósticos e prescrições; e um conjunto de **ficheiros em formato CSV**, enviados diariamente por laboratórios externos, contendo resultados de análises clínicas como hemogramas, bioquímica e microbiologia. A integração destas duas fontes, dada a sua marcada heterogeneidade em termos de formatos, nomenclatura de parâmetros e identificadores de doentes, constitui o principal desafio do trabalho.

1.3. Motivação e Objetivos

A motivação para o desenvolvimento deste trabalho decorre da necessidade de estruturar, de forma rigorosa e documentada, o processo de recolha e integração de dados clínicos heterogéneos. A sensibilidade dos dados envolvidos, registos clínicos de doentes identificados, torna crítica a existência de mecanismos de proteção de dados, validação, controlo de qualidade e rastreabilidade de todas as operações realizadas pelo agente. Os principais objetivos do trabalho são:

- Definir e caraterizar o agente de angariação no contexto da plataforma de saúde;
- Identificar e descrever as fontes de dados e os respetivos requisitos de recolha;
- Especificar os processos de extração, conciliação, preparação e carregamento dos dados na **staging area**;
- Definir os mecanismos de controlo e registo de operações;
- Modelar o processo completo através de um **diagrama BPMN**.

2. Agente de angariação de dados

2.1. Definição de Agente

O agente de angariação de dados concebido no âmbito deste trabalho é um processo automatizado responsável pela recolha sistemática, validação e integração de informação clínica proveniente de duas fontes heterogéneas, preparando-a para carregamento numa *staging area* que antecede o *data warehouse*.

O agente opera em regime de processamento em lote (*batch*), com execução diária (*cron job*) no período noturno às 05:00 (GMT 00:00) a fim de não interferir com os sistemas operacionais das unidades de saúde e dos laboratórios em horário de funcionamento. Esta periodicidade justifica-se pelo volume de registos clínicos e de resultados de análises gerados diariamente pelo conjunto das entidades aderentes.

O agente é composto por quatro módulos funcionais principais: extração, conciliação, preparação e carregamento. Cada módulo é acompanhado por um subprocesso transversal de controlo e registo de operações, que garante a rastreabilidade completa de cada ciclo de angariação.

2.2. Objetivos

Os objetivos do agente de decisão aplicado a contexto deste projeto(informação clínica) são:

- Recolher dados clínicos estruturados a partir da base de dados relacional do sistema de informação clínica
- Integrar dados de análises laboratoriais provenientes de ficheiros CSV.
- Garantir a consistência e qualidade dos dados extraídos através de mecanismos de validação e controlo
- Transformar e preparar os dados para armazenamento na **staging area**
- Suportar a posterior integração dos dados no Data Warehousing destinado a análise de indicadores de saúde

3. Identificação das fontes de informação

3.1. Base de dados relacional

A primeira fonte de dados a que o agente de angariação irá aceder consiste numa base de dados relacional, responsável por suportar o sistema de informação clínica atualmente em utilização. Esta base de dados contém registos estruturados e atualizados relativos à atividade clínica, incluindo consultas, diagnósticos, prescrições médicas e episódios de doentes internados mas apenas os presentes na imagem a baixo serão importantes para nós.

A informação encontra-se organizada segundo um modelo relacional, estruturado em tabelas interligadas através de chaves primárias e estrangeiras, permitindo a representação consistente das diferentes entidades clínicas e das suas relações.

Esta fonte caracteriza-se por apresentar um elevado grau de estruturação e integridade, garantindo maior fiabilidade dos dados armazenados, sendo por isso considerada a principal fonte de informação para o agente de recolha.

A estrutura da base de dados pode ser representada de forma simplificada através das seguintes tabelas principais:

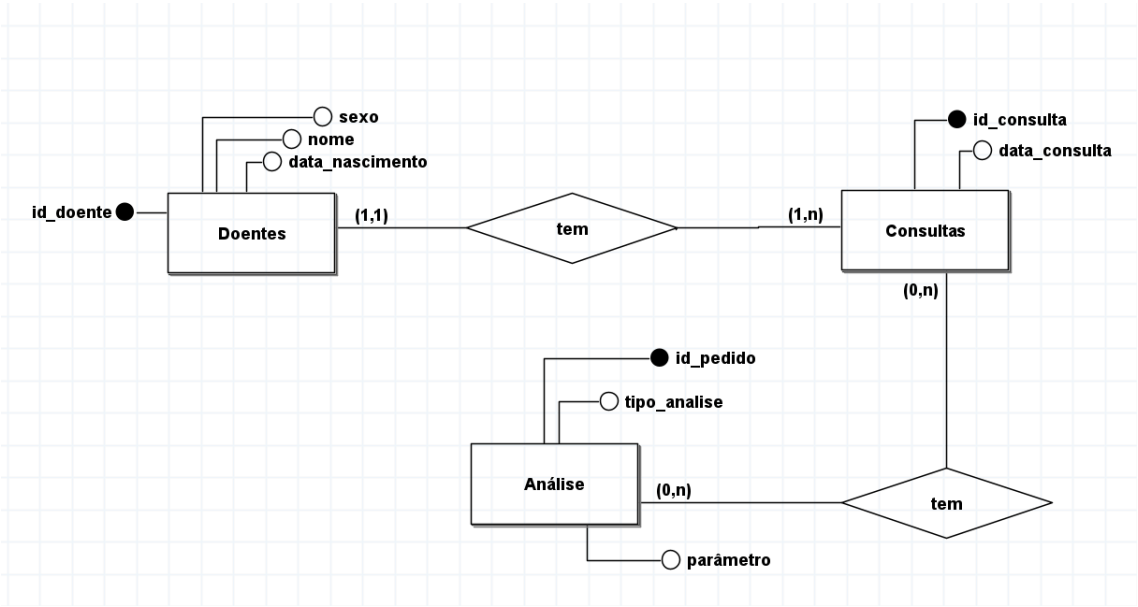

Figura 1: Diagrama Conceptual BD

É de notar que id_doente é o mesmo que número de utente presente no cartão de cidadão.

3.2. Ficheiros CSV

A segunda fonte de dados considerada consiste num conjunto de ficheiros em formato CSV, enviados diariamente por laboratórios externos. Cada ficheiro contém resultados de análises clínicas realizadas aos doentes, mas está organizado por tipo de exame, nomeadamente:

Hemograma – registos relacionados com hemoglobina, leucócitos, plaquetas, entre outros parâmetros sanguíneos.

Bioquímica – registos de exames bioquímicos, como glicose, creatinina, colesterol, entre outros.

Microbiologia – registos de testes microbiológicos, incluindo culturas e resultados qualitativos (Positiva/ Negativa).

Os ficheiros são armazenados numa diretoria específica do sistema e gerados de forma independente pelos laboratórios, não estando integrados diretamente no sistema central de informação clínica. Cada ficheiro possui uma estrutura relativamente simples, composta pelas seguintes colunas:

- n_utente (identifador do doente)
- data_análise (data da análise clínica)
- parâmetro (parâmetro medido na analise)
- resultado (resultado obtido na análise)
- unidade (unidade de medida da análise)

Ficheiro CSV	Tipo de Exame	Data de geração	Nº de registos
hemograma_2026-03-18.csv	Hemograma	2026-03-18	5k
bioquimica_2026-03-18.csv	Bioquímica	2026-03-18	5k
microbiologia_2026-03-18.csv	Microbiologia	2026-03-18	5k

Tabela 1: Informação relativa aos ficheiros CSV

n_utente	Full_name	birthday date	gender	n_Appointment	Appointment_date	parameter	result	unit
12345	João Pedro Ribeiro Lopes da Silva	2/7/2004	M	22	3/18/2026	Hemoglobina	13.5	g/dL
12346	Gabriela Veloso Antunes	24/03/2003	F	25	3/19/2026	Leucócitos	5.8	10^9/L
12347	Oliver Favero Teixeira	9/6/2004	M	26	3/19/2026	Hemoglobina	12.9	g/dL
12348	Guilherme Pinto Pinho	14/01/2004	M	29	3/20/2026	Plaquetas	220	10^9/L
12349	Rita Mota Machado	30/7/2004	F	30	3/20/2026	Leucócitos	6.1	10^9/L

Figura 2: CSV - hemograma_2026-03-18

n_utente	Full_name	birthday date	gender	n_Appointment	Appointment_date	parameter	result	unit
12350	Paulo Alexandre Rodrigues Alves	3/4/2004	M	21	3/18/2026	Glicose	98	mg/dL
12345	João Pedro Ribeiro Lopes da Silva	2/7/2004	M	27	3/19/2026	Colesterol	190	mg/dL
12348	Guilherme Pinto Pinho	14/01/2004	M	28	3/19/2026	Creatinina	1.1	mg/dL
12351	Filipa Abreu Mendes Fernandes	15/10/1990	F	32	3/20/2026	Glicose	102	mg/dL
12350	Paulo Alexandre Rodrigues Alves	2/7/2004	M	34	3/20/2026	Colesterol	200	mg/dL

Figura 3: CSV - bioquimica_2026-03-18

n_utente	Full_name	birthday date	gender	n_Appointment	Appointment_date	parameter	result	unit
12349	Rita Mota Machado	30/7/2004	F	23	3/18/2026	Cultura	Negativa	-
12350	Paulo Alexandre Rodrigues Alves	2/7/2004	M	24	3/19/2026	Cultura	Positiva	-
12351	Filipa Abreu Mendes Fernandes	15/10/1990	F	31	3/19/2026	Cultura	Negativa	-
12347	Oliver Favero Teixeira	9/6/2004	M	33	3/20/2026	Cultura	Positiva	-
12346	Gabriela Veloso Antunes	24/03/2003	F	35	3/20/2026	Cultura	Negativa	-

Figura 4: CSV - microbiologia_2026-03-18

Apesar da sua simplicidade, esta fonte apresenta um menor grau de estruturação e controlo relativamente à base de dados relacional, sendo uma fonte semi-estruturada, podendo existir variações na nomenclatura dos parâmetros, formatos de datas e unidades de medida.

Estas características tornam os ficheiros CSV uma fonte de dados heterogénea, exigindo a aplicação de mecanismos de validação, normalização e conciliação para garantir a correta integração com os dados provenientes da base de dados relacional.

4. Requisitos de Recolha de Dados

4.1. Dados a extrair

O agente de angariação de dados deverá extrair informação relevante proveniente das duas fontes de dados consideradas, de forma a permitir a construção de uma visão integrada da informação clínica dos doentes.

Esta extração deverá ser sequencial. Primeiro a extração da base de dados relacional e depois os csv.

4.1.1. Extração da Base de Dados Relacional

A extração dos dados da base de dados relacional é realizada de forma incremental, consultando exclusivamente os registos cujo campo `updated_at` seja posterior ao *timestamp* do último ciclo de extração bem-sucedido, armazenado numa tabela de controlo do próprio agente. As tabelas alvo são: `Doentes`, `Consultas` e `Analise`. Para cada tabela, o agente executa uma consulta SQL parametrizada, recolhe os resultados para memória e regista o número de linhas obtidas. Em caso de falha de ligação, o agente realiza até três tentativas com intervalo crescente antes de registar o erro e interromper o ciclo.

4.1.2. Extração dos Ficheiros CSV

A extração dos ficheiros *CSV* inicia-se com a enumeração dos ficheiros presentes no email da instituição em que apenas emails de fontes confiáveis (dos laboratórios) são usados e com o seguinte prefixo [R-ANALISE] que ainda não foram processados, comparando à data e hora em que o email chegou e o último ciclo do agente. Para cada ficheiro, o agente deteta automaticamente o delimitador (vírgula ou ponto e vírgula) e a codificação de caracteres. Após leitura, os dados são carregados para memória, sendo de imediato aplicadas verificações de integridade estrutural, nomeadamente a presença dos campos obrigatórios e a conformidade dos tipos de dados esperados. Cada ficheiro contém resultados de análises clínicas enviados pelo laboratório emissor, incluindo os dados de identificação do doente (`n_utente`, `Full_name`,`birthday_date`, `gender`), a referência à consulta associada (`n_Appointment`,`Appointment_date`), e os dados do resultado laboratorial (`parameter`, `result`,`unit`).

Para ser possível de juntar a informação o agente terá de analisar o nome do csv para saber o tipo_analise a fim de conseguir identificar de que pedido é proveniente.

4.2. Frequência de recolha

A recolha de dados será realizada de forma periódica, com uma frequência diária, no período noturno, 05:00 (GMT 00:00) de modo a garantir a atualização contínua da informação clínica disponível para análise.

No caso da base de dados relacional, a extração incidirá sobre os registos mais recentes, permitindo a integração de novas consultas, diagnósticos e prescrições à medida que são registados no sistema.

Relativamente aos ficheiros CSV, a recolha será efetuada sempre que novos ficheiros sejam disponibilizados pelos laboratórios externos, prosseguindo assim a extração dos novos registos de cada CSV, assumindo-se uma periodicidade diária associada ao envio dos resultados das análises clínicas.

4.3. Volume de dados

O volume de dados esperado é moderado, refletindo a atividade clínica diária das unidades de saúde consideradas.

No caso da base de dados relacional, prevê-se a existência de um volume significativo de dados históricos acumulados. No entanto, o agente de angariação incidirá sobretudo sobre os registos mais recentes, reduzindo assim a quantidade de dados a processar em cada execução.

Relativamente aos ficheiros CSV, o volume de dados dependerá do número de análises realizadas. Espera-se que diáriamente seja enviado pelos laboratórios externos, pelo menos um dos tipos de análise possivéis, sendo expectável cada um conter diversos registos de resultados laboratoriais.

De um modo geral, o volume de dados é considerado gerível, não se prevendo limitações significativas ao nível do processamento ou armazenamento na staging area.

4.4. Condições de acesso

O acesso às fontes de dados deverá respeitar os requisitos de segurança e confidencialidade associados ao tratamento de informação clínica.

No caso da base de dados relacional, o agente de angariação deverá dispor de permissões de leitura adequadas, utilizando credenciais de acesso de um utilizador de sistema dedicado a esse processo com privilégios de estritos de apenas leitura, garantindo o acesso aos dados necessários sem comprometer a integridade do sistema operacional.

Relativamente aos ficheiros CSV, estes deverão estar disponíveis numa diretoria previamente definida e acessível ao agente, sendo necessário garantir que os ficheiros se encontram completos e corretamente formatados antes do seu processamento.

Adicionalmente, deverão ser respeitadas as normas e regulamentações aplicáveis à proteção de dados pessoais, assegurando a confidencialidade e integridade da informação ao longo de todo o processo de recolha e integração.

5. Conciliação e Preparação de Dados

5.1. Identificação de Correspondências

A identificação de correspondências consiste no processo de associação entre os dados provenientes das diferentes fontes, de forma a garantir que a informação relativa ao mesmo doente e ao mesmo pedido de análise é corretamente integrada.

Uma vez que o sistema agrega dados de múltiplas unidades de saúde independentes, cada uma com os seus próprios sequenciais de identificadores, o `id_doente` não é globalmente único, o mesmo valor pode existir em bases de dados de clínicas distintas, referindo-se a doentes diferentes. Para resolver esta ambiguidade, o agente atribui a cada registo extraído um identificador composto, formado pela combinação do código interno da unidade de saúde (`id_fonte`) com o identificador original (`id_doente`). Este mecanismo garante a unicidade global dos registos na *staging area* sem necessidade de alterar os sistemas fonte.

A correspondência entre os resultados de análises provenientes dos ficheiros CSV e os pedidos de análise existentes na base de dados relacional é estabelecida através de dois critérios combinados: o nome do ficheiro CSV, que determina o tipo de análise (`hemograma`, `bioquimica` ou `microbiologia`), correspondendo ao campo `tipo_analise` da tabela `Análise`; e a identificação da consulta associada, efetuada através de um identificador composto formado pela combinação do código da unidade de saúde (`id_fonte`) com o `n_Appointment` e a `Appointment_date` do CSV, que são cruzados com o `id_consulta` e a `data_consulta` da tabela `Consultas` da BD relacional.

Este mecanismo é necessário uma vez que o `n_Appointment` é sequencial dentro de cada unidade de saúde, podendo o mesmo valor existir em unidades distintas referindo-se a consultas diferentes. A inclusão da `Appointment_date` reforça a correspondência, reduzindo a ambiguidade em caso de colisão de identificadores entre fontes.

Nos casos em que a correspondência não seja possível — por ausência dos campos necessários ou por não existir nenhuma consulta registada na BD relacional com o par (`id_fonte`, `n_Appointment`, `Appointment_date`) indicado no CSV — o agente encaminha esses registos para quarentena, sinalizando-os com a razão da falha. No ciclo de angariação seguinte, o agente reavalia os registos em quarentena: caso a consulta correspondente entretanto se encontre disponível na BD relacional, os registos são processados normalmente e carregados nas tabelas prontas; caso contrário, permanecem em quarentena para posterior averiguação manual.

5.2. Validação dos Dados

A validação é aplicada aos dados provenientes de ambas as fontes e incide sobre os seguintes aspetos:

- Verificação da presença dos atributos obrigatórios, nomeadamente `id_fonte` e `id_doente`, a combinação de `n_Appointment` e `Appointment_date` para identificação da consulta associada, e a data dos registos;
- Validação dos formatos dos dados, nomeadamente datas no formato ISO 8601 e valores numéricos associados a resultados laboratoriais;
- Deteção de valores inválidos ou inconsistentes, como resultados negativos quando não aplicáveis, datas de análise anteriores à data do pedido, ou valores fora dos intervalos fisiologicamente possíveis;

Os registos que não cumpram os critérios de validação definidos são sinalizados com uma `flag` adequada. Consoante a severidade da anomalia, o registo pode ser corrigido automaticamente, colocado em quarentena para revisão manual. Em qualquer dos casos, a ocorrência é registada nas logs do agente.

5.3. Resolução de Conflitos

Podem ocorrer conflitos quando o mesmo dado está presente em mais do que uma fonte com valores divergentes. As situações mais comuns são:

- **Conflito de valores demográficos**: o nome ou a data de nascimento de um doente diferem entre a base de dados de uma clínica e outra. Neste caso, o agente usa a data de nascimento mais recente.

5.4. Limpeza dos Dados

A limpeza dos dados tem como objetivo corrigir ou eliminar registos com problemas de qualidade antes do carregamento na *staging area*. As operações realizadas são:

- **Normalização de nomenclatura**: os nomes de parâmetros laboratoriais são convertidos para a nomenclatura normalizada da plataforma, através de uma tabela de mapeamento centralizada. Os parâmetros não mapeáveis são registados como desconhecidos e sinalizados;
- **Conversão de formatos**: as datas são convertidas para ISO 8601, os campos de texto são normalizados quanto a capitalização e espaços em branco, e os separadores decimais são homogenizados;
- **Tratamento de valores nulos**: os campos opcionais em falta são preenchidos com valores nulos explícitos; os campos obrigatórios em falta determinam a sinalização do registo;
- **Pseudonimização**: o número de utente de saúde é substituído por um identificador sintético reversível, armazenado numa tabela de correspondência em ambiente seguro, em conformidade com o RGPD.

6. Preparação e Organização dos Dados

6.1. Preparação das tabelas (Utentes, Consultas e Analises)

Nesta fase, o agente de angariação procede à preparação dos dados recolhidos, organizando a informação em estruturas adequadas para armazenamento na staging area.

Inicialmente, são aplicadas verificações adicionais de consistência, nomeadamente a identificação de valores nulos em campos obrigatórios e a deteção de possíveis inconsistências nos dados.

Em particular, consideram-se como campos obrigatórios atributos como o identificador do utente, o nome, os identificadores das consultas, as respetivas datas e os resultados das análises. A ausência de valores nestes campos compromete a validade dos registos.

Adicionalmente, são identificadas situações de inconsistência, como a existência de registos duplicados ou a presença de múltiplas análises associadas ao mesmo utente no mesmo período temporal sem justificação válida.

6.2. Transformações

Os registos que não cumpram os critérios definidos são encaminhados para tabelas de quarentena (por exemplo, utentesQUA, consultasQUA e analisesQUA), permitindo a sua posterior análise e eventual correção, sem comprometer a qualidade dos dados processados.

Para além das operações de validação, são realizadas transformações com o objetivo de uniformizar os dados provenientes das diferentes fontes. Estas incluem a normalização de formatos de datas (ISO 8601), a conversão de tipos de dados, por exemplo númericos para resultados de análise, e a padronização da representação de valores, como espaços em branco desnecessários, capitalização da primeira letra.

Adicionalmente, é efetuada a harmonização da nomenclatura dos atributos, uma vez que as diferentes fontes utilizam designações distintas para representar a mesma informação.

A título exemplificativo, apresentam-se algumas correspondências entre atributos provenientes dos ficheiros CSV e da base de dados relacional:

Atributo CSV	Atributo BD Relacional	Atributo Normalizado (Staging)
`n_utente`	`id_doente`	`idUtente`
`Full_name`	`nome_completo`	`nome`
`birthday_date`	`data_nasc`	`data_nascimento`
`gender`	`sexo`	`sexo`
`n_Appointment`	`id_consulta`	`id_consulta`
`Appointment_date`	`data_consulta`	`data_consulta`
`parameter`	`parametro`	`parametro`
`result`	`resultado`	`resultado`
`unit`	`unidade`	`unidade`

Tabela 2: Mapeamento de atributos entre fontes para a staging area

No caso da base de dados relacional, atributos como id_doente são igualmente normalizados para idUtente, garantindo consistência na identificação dos registos.

Esta uniformização permite garantir a consistência dos dados e facilitar o processo de integração.

6.3. Cálculos derivados

Adicionalmente, são efetuados cálculos derivados com o objetivo de enriquecer a informação disponível, nomeadamente:

- **Cálculo da idade do utente**: determinado a partir da data de nascimento e da data de referência do ciclo de extração.
- **Intervalo entre pedido e realização da análise**: calculado a partir da diferença entre a `data_pedido` (registada na BD relacional) e a `data_analise` (presente nos ficheiros CSV), permitindo identificar eventuais atrasos laboratoriais ou atrasos por parte do utente em realizar as análises.

7. Carregamento na Staging Area

7.1. Definição de staging area

A *staging area* (DSA) consiste numa área intermédia de armazenamento utilizada no processo de integração de dados, onde a informação recolhida a partir das diferentes fontes é temporariamente armazenada antes de ser integrada no data warehouse.

No contexto do presente trabalho, a staging area tem como principal objetivo centralizar os dados provenientes da base de dados relacional e dos ficheiros CSV, após as etapas de extração, validação e transformação.

Esta área permite isolar os sistemas de origem dos processos analíticos, garantindo que eventuais operações de tratamento de dados não afetam o funcionamento dos sistemas operacionais.

Adicionalmente, a staging area facilita a organização, controlo e preparação dos dados, assegurando que a informação se encontra estruturada, consistente e pronta para utilização em etapas posteriores do sistema.

7.2. Processo de carregamento

O processo de carregamento dos dados na staging area é realizado em várias etapas, de forma a garantir a correta integração da informação proveniente das diferentes fontes.

Numa fase inicial, os dados provenientes da base de dados relacional são extraídos e armazenados em tabelas intermédias, nomeadamente utentes1, consultas1 e analises1.

De forma semelhante, os dados provenientes dos ficheiros CSV são carregados em tabelas distintas, designadamente utentes2, consultas2 e analises2, permitindo manter a separação entre as diferentes origens de dados.

Posteriormente, os dados são sujeitos a processos de validação e verificação de consistência. Os registos que apresentem valores nulos em campos obrigatórios ou inconsistências são encaminhados para tabelas de quarentena (utentesQUA, consultasQUA e analisesQUA).

Por outro lado, os registos que cumprem os critérios definidos são considerados válidos e são integrados nas tabelas finais de preparação (utentesRDY, consultasRDY e analisesRDY), representando a versão consolidada e pronta a utilizar dos dados.

8. Controlo de Qualidade e Registo

8.1. Controlo de qualidade

Todos os dados inseridos nas tabelas da DSA (Utentes1, Utentes2, Consultas1, Consultas2, Analises1, Analises2) são submetidos a analises de integridade:

Campos obrigatórios preenchidos (idUtente, data_consulta)
- Formatos de datas corretos
- Valores numéricos válidos

Para os dados provenientes de CSV, verifica-se a consistência entre unidades e nomenclatura dos parâmetros, garantindo que os resultados laboratoriais podem ser integrados posteriormente com a base de dados relacional. Dados que não passam nas verificações básicas são automaticamente direcionados para a quarentena (clientesQuarentena / analisesQuarentena) para análise posterior.

8.2. Tratamento de erros

Sempre que ocorre uma falha de extração (ex: ficheiro CSV em falta, ligação à base de dados falha), o processo regista o erro e bloqueia o carregamento da fonte afetada, evitando inconsistências na DSA. Durante o processamento na DSA, qualquer anomalia nos dados (ex: parâmetros inválidos, duplicados, identificadores em falta) é capturada e o registo é marcado como quarentena, mantendo os dados corretos separados para processamento posterior. Todos os erros críticos e não críticos são categorizados, permitindo auditorias futuras e correções dirigidas.

8.3. Registo (logging)

O agente mantém logs detalhados para todas as operações:

- **Extração:** ligação às fontes, sucesso ou falha, ficheiros processados
- **Inserção na DSA:** número de registos inseridos por tabela, identificação de dados enviados para quarentena transformação e conciliação: número de registos tratados, métricas de normalização
- **Carregamento final:** resumo de registos processados, falhas e total de dados válidos

Estes logs permitem rastreabilidade completa, fornecendo métricas de execução e permitindo auditar o processo completo de angariação de dados clínicos.

9. Estruturação do Fluxo de Operações

9.1. Sequência do Processo

O fluxo de operações do agente de angariação segue uma sequência lógica e ordenada, composta pelas seguintes fases:

1. **Inicialização**: o agente é ativado pelo *cron job* às 05:00 (GMT 00:00), verifica a disponibilidade da BD relacional e da *staging area*, consulta a tabela `controlo_agente` para obter o *timestamp* do último ciclo bem-sucedido e regista o início da execução nas *logs*;
2. **Extração da BD Relacional**: execução das *queries* incrementais sobre as tabelas `Doentes`, `Consultas` e `Análise`, selecionando apenas os registos cujo campo `updated_at` seja posterior ao *timestamp* do último ciclo bem-sucedido. Os resultados são carregados nas tabelas intermédias.
3. **Extração dos Ficheiros CSV**: enumeração dos emails não processados de remetentes autorizados com o prefixo `[R-ANALISE]`, leitura de cada ficheiro com deteção automática do delimitador e codificação de caracteres, e carregamento na tabela intermédia. O tipo de análise é inferido a partir do nome do ficheiro (`hemograma`, `bioquimica` ou `microbiologia`);
4. **Decomposição e Normalização do CSV**: cada linha da tabela intermédia do csv é decomposta nas três entidades correspondentes: doente, consulta e análise com mapeamento dos atributos para a nomenclatura normalizada da *staging area*, conforme definido no Capítulo 6;
5. **Conciliação e Validação**: os registos decompostos do CSV são conciliados com os registos da BD relacional através dos identificadores compostos (`id_fonte` + `id_doente` para doentes; `id_fonte` + `n_Appointment` + `Appointment_date` para consultas e análises). São aplicadas as regras de validação definidas no Capítulo 5. Os registos não conciliáveis ou inválidos são encaminhados para as tabelas de quarentena com registo da razão da sinalização;
6. **Reavaliação da Quarentena**: os registos em quarentena de ciclos anteriores são reavaliados com os dados entretanto disponibilizados. Os que encontram correspondência são processados e movidos para as tabelas prontas, os restantes permanecem em quarentena para revisão manual;
7. **Carregamento nas Tabelas Prontas**: os registos válidos e conciliados são inseridos nas tabelas `doentesRDY`, `consultasRDY` e `analisesRDY`. Nesta fase são também calculados os atributos derivados: idade do utente, intervalo entre consulta e realização da análise, e classificação de resultados fora de referência;
8. **Finalização**: atualização da tabela `controlo_agente` com o *timestamp* do ciclo concluído e o estado final da execução, geração do relatório sumário de qualidade e registo do fim da execução nas *logs*.

9.2. Eventos

O processo contempla os seguintes eventos relevantes:

- **Evento de início**: ativação pelo *cron job* às 05:00 (GMT 00:00), que desencadeia o arranque do ciclo de angariação;
- **Evento de erro crítico**: desencadeado quando ocorre uma falha que impede a continuação do ciclo, como a indisponibilidade da BD relacional após três tentativas ou a impossibilidade de acesso à *staging area*. Provoca a interrupção controlada do processo com notificação ao administrador;
- **Evento de quarentena**: desencadeado quando um registo não passa na validação ou não encontra correspondência, sinalizando-o para revisão;
- **Evento de fim com sucesso**: conclusão normal do ciclo, sem erros críticos e sem registos em quarentena, com atualização da tabela `controlo_agente`;

- **Evento de fim com sucesso parcial**: conclusão do ciclo sem erros críticos, mas com registos encaminhados para quarentena, que ficam pendentes de reavaliação no ciclo seguinte;
- **Evento de fim com erro**: conclusão anómala do ciclo por erro crítico, com registo do estado de falha na tabela `controlo_agente` e *timestamp* não atualizado, de forma a que o ciclo seguinte reprocesse o mesmo intervalo temporal.

9.3. Decisões

Os principais pontos de decisão ao longo do fluxo são:

- **BD relacional disponível?**: verificado na inicialização. Caso falhe regista erro crítico e termina o ciclo;
- **Existem emails CSV não processados?**: se não existirem ficheiros novos, o agente regista o facto nas *logs* e prossegue apenas com a extração da BD relacional, sem interromper o ciclo;
- **O ficheiro CSV tem estrutura válida?**: verificação da presença dos campos obrigatórios e da conformidade dos tipos de dados. Se inválido, o ficheiro é rejeitado na totalidade e registado nas *logs*, prosseguindo o processamento dos restantes ficheiros;
- **O registo passa na validação?**: se não cumprir os critérios de completude, conformidade ou consistência, é encaminhado para a tabela de quarentena correspondente com indicação da anomalia;
- **Existe correspondência na BD relacional?**: cruzamento do par (`id_fonte`, `n_Appointment`, `Appointment_date`) do CSV com (`id_fonte`, `id_consulta`, `data_consulta`) da BD. Se não existir correspondência, o registo é colocado em quarentena para reavaliação no ciclo seguinte;
- **O registo em quarentena é agora resolvível?**: reavaliado em cada ciclo. Se a correspondência entretanto existir na BD, o registo é processado e movido para a tabela pronta; caso contrário, permanece em quarentena para revisão manual.

10. Modelação em BPMN

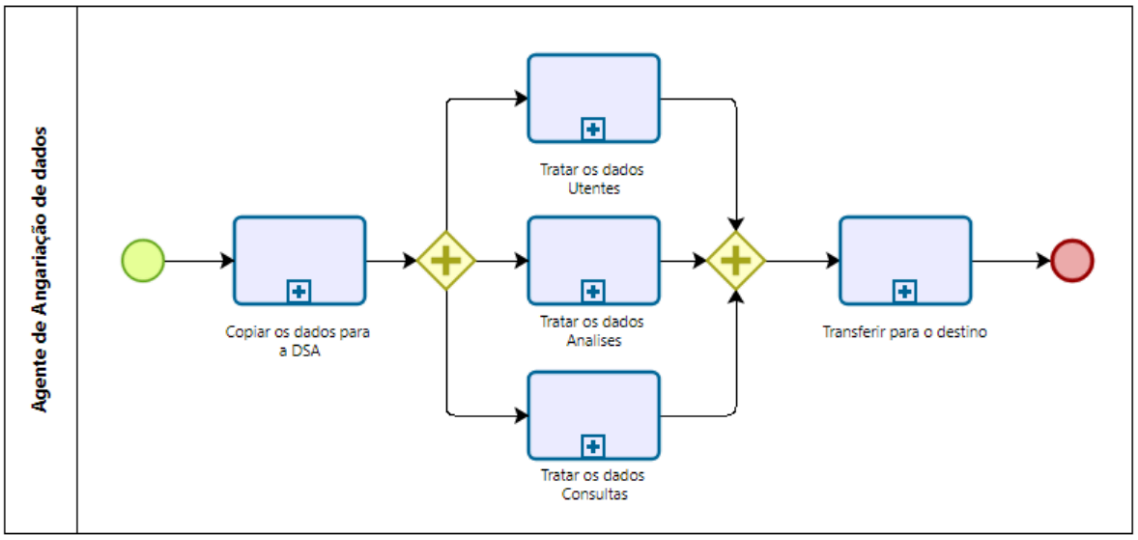

Figura 5: Diagrama BPMN - Agente Angariação de dados

Descrição: Esta figura ilustra a pista (lane) do Agente de Angariação de Dados, que atua como o orquestrador principal do fluxo de integração. O processo inicia-se com um Start Event, que representa o gatilho de execução.

- **Gatilho por Evento:** Acionado pela receção de ficheiros CSV (dados das lojas ou clínicas remotas);
- **Gatilho Temporal:** Uma rotina diária que extrai as atualizações diretamente da Base de Dados central.

Em ambos os casos, o primeiro passo é a cópia integral para a DSA: Uma fase inicial de extração bruta, onde os dados são movidos para a Data Staging Area para isolar os sistemas operacionais.

Tratamento em Paralelo: Através de um Parallel Gateway, o processo ramifica-se para tratar de forma simultânea as entidades de Utentes, Análises e Consultas. Esta abordagem garante a independência das regras de limpeza e a otimização da performance do motor de ETL.

Transferência Final: Após a sincronização dos fluxos paralelos, os dados consolidados são carregados no destino final (Data Warehouse).

O fluxo encerra-se num End Event, confirmando que os dados clínicos foram validados e estão prontos para consumo analítico.

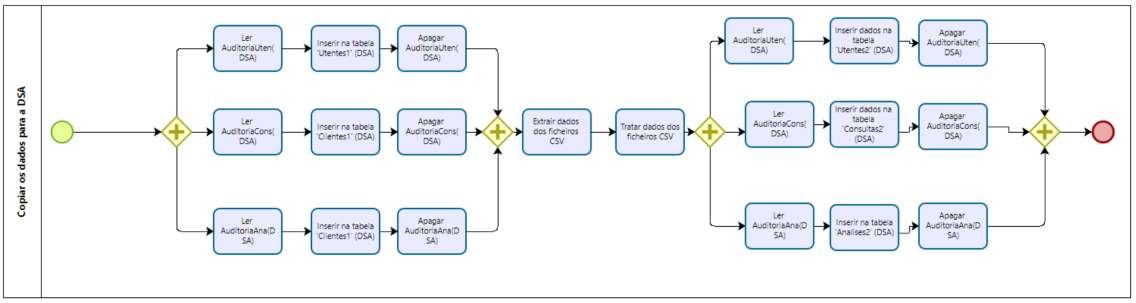

Figura 6: Diagrama BPMN - Copiar dados para a DSA

O diagrama BPMN apresentado representa o processo de recolha e carregamento de dados para a staging area, evidenciando a integração de dados provenientes de múltiplas fontes.

Numa primeira fase, é realizada a extração de dados da base de dados relacional, sendo estes inseridos em tabelas intermédias distintas (Utentes1, Consultas1 e Análises1), após leitura e controlo através de mecanismos de auditoria. Estas operações são executadas em paralelo, permitindo maior eficiência no processamento.

Posteriormente, o processo avança para a extração e tratamento dos dados provenientes dos ficheiros CSV, que são igualmente carregados em tabelas intermédias separadas (Utentes2, Consultas2 e Análises2), mantendo a distinção entre as diferentes origens de dados.

Ao longo do processo, são aplicadas operações de validação e controlo, garantindo a integridade dos dados antes da sua consolidação. O fluxo termina com a integração dos dados na staging area, assegurando que a informação se encontra preparada para as etapas seguintes do sistema.

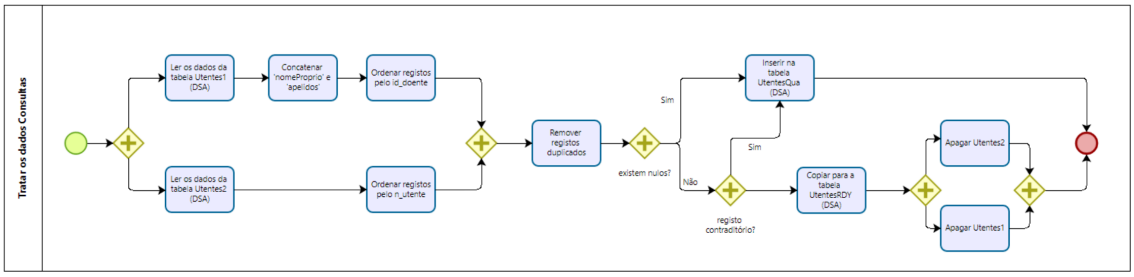

Figura 7: Diagrama BPMN - Dados Utentes

O diagrama BPMN apresentado descreve o processo de tratamento e validação dos dados relativos aos utentes, após a sua carga inicial na staging area.

Numa fase inicial, os dados provenientes das tabelas Utentes1 e Utentes2 são lidos e preparados, incluindo a concatenação de atributos (como nome próprio e apelidos) e a ordenação dos registos com base no identificador do utente, garantindo a uniformização da informação proveniente das diferentes fontes.

De seguida, é realizada a remoção de registos duplicados, assegurando a unicidade dos dados. Posteriormente, são aplicadas verificações de qualidade, nomeadamente a deteção de valores nulos e a identificação de possíveis inconsistências.

Os registos que não cumprem os critérios definidos são encaminhados para a tabela de quarentena (UtentesQUA), enquanto os registos válidos são integrados na tabela final UtentesRDY, representando dados consistentes e prontos para utilização.

Por fim, as tabelas intermédias (Utentes1 e Utentes2) são limpas, garantindo a preparação do sistema para futuras execuções do processo.

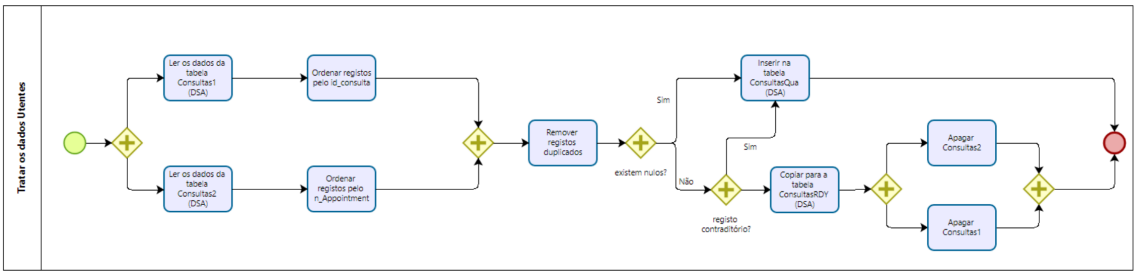

Figura 8: Diagrama BPMN - Dados Consultas

O diagrama BPMN apresentado descreve o processo de tratamento e validação dos dados relativos às consultas, após a sua carga inicial na staging area.

Numa primeira fase, os dados provenientes das tabelas Consultas1 e Consultas2 são lidos e ordenados de acordo com os respetivos identificadores, permitindo uniformizar a estrutura dos registos provenientes das diferentes fontes.

De seguida, é realizada a remoção de registos duplicados, assegurando que cada consulta é representada de forma única. Posteriormente, são aplicadas verificações de qualidade, nomeadamente a deteção de valores nulos e a identificação de possíveis inconsistências nos dados.

Os registos que não cumprem os critérios definidos são encaminhados para a tabela de quarentena (ConsultasQUA), enquanto os registos válidos são integrados na tabela final ConsultasRDY, representando dados prontos para utilização.

Por fim, as tabelas intermédias (Consultas1 e Consultas2) são limpas, garantindo a preparação do sistema para futuras execuções do processo.

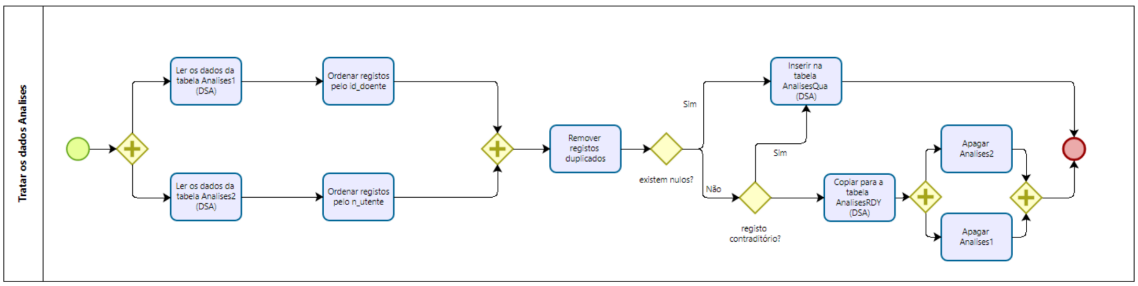

Figura 9: Diagrama BPMN - Dados Análises

O diagrama BPMN apresentado descreve o processo de tratamento e validação dos dados relativos às analises, após a sua carga inicial na staging area.

Numa primeira fase, os dados provenientes das tabelas Analises1 e Analises2 são lidos e ordenados de acordo com os respetivos identificadores, permitindo uniformizar a estrutura dos registos provenientes das diferentes fontes.

De seguida, é realizada a remoção de registos duplicados, assegurando que cada consulta é representada de forma única. Posteriormente, são aplicadas verificações de qualidade, nomeadamente a deteção de valores nulos e a identificação de possíveis inconsistências nos dados.

Os registos que não cumprem os critérios definidos são encaminhados para a tabela de quarentena (AnalisesQUA), enquanto os registos válidos são integrados na tabela final AnalisesRDY, representando dados prontos para utilização.

Por fim, as tabelas intermédias (Analies1 e Analies2) são limpas, garantindo a preparação do sistema para futuras execuções do processo.

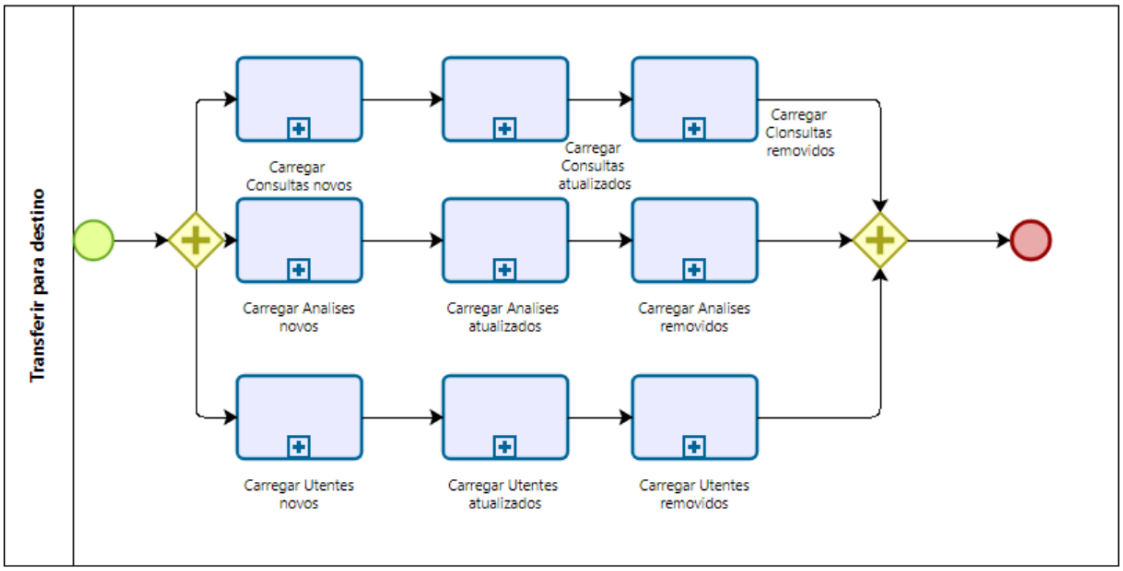

Figura 10: Diagrama BPMN - Dados para o destino

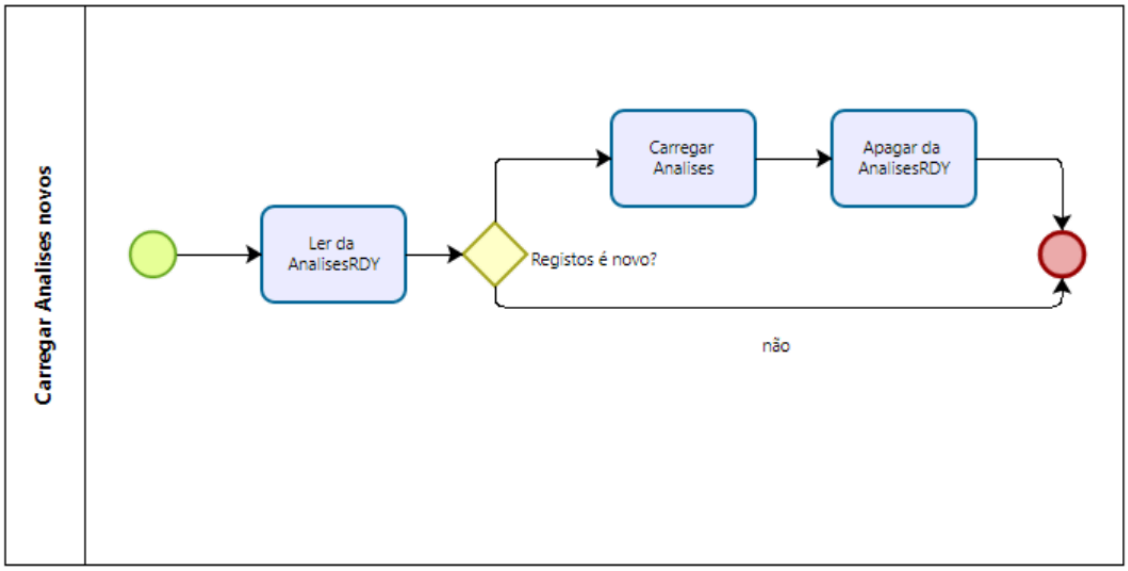

Figura 11: Diagrama BPMN - Analises novas

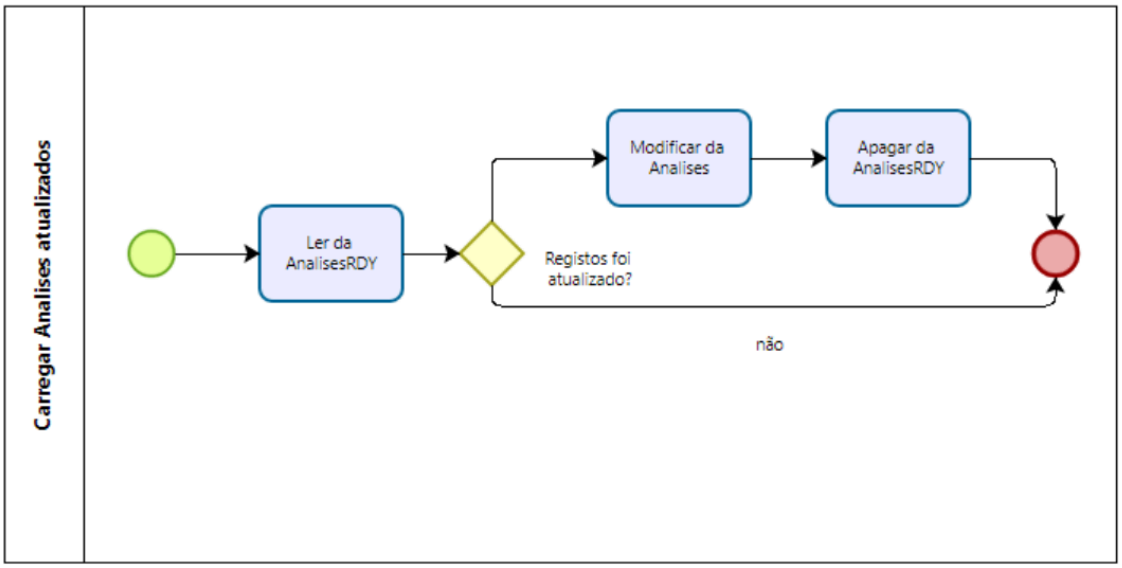

Figura 12: Diagrama BPMN - Analises atualizadas

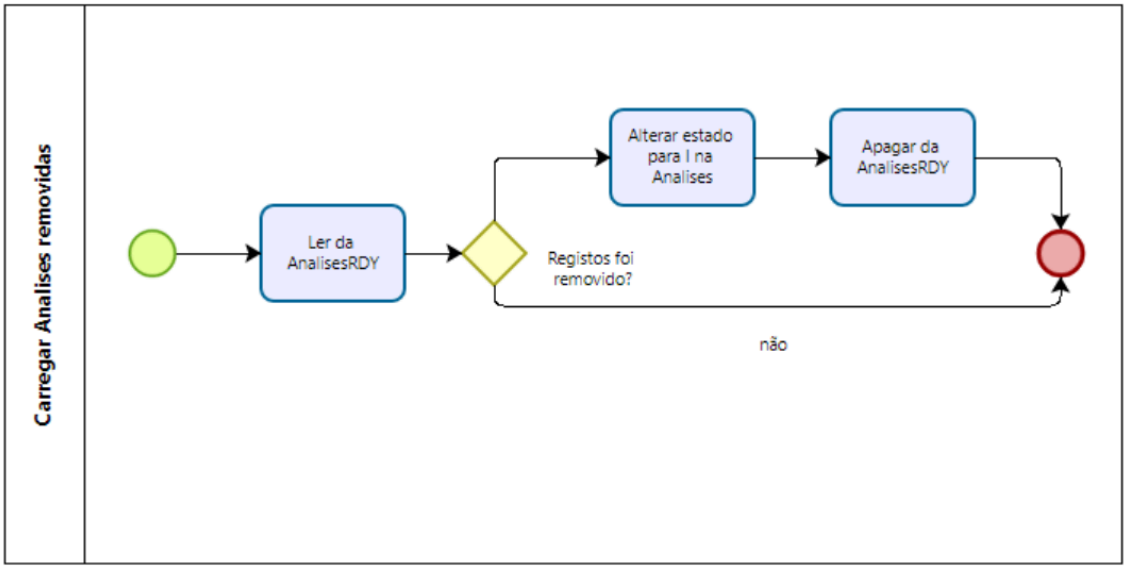

Figura 13: Diagrama BPMN - Analises removidas

Os diagramas relativos ao tratamento dos dados de utentes e consultas apresentam uma estrutura semelhante. Assim, optou-se por incluir no relatório apenas um exemplo representativo, de forma a evitar redundância na apresentação.

11. Conclusões e Trabalho Futuro

O presente trabalho permitiu conceber e modelar de forma detalhada um agente de angariação de dados aplicado ao domínio da saúde, com o objetivo de integrar informação clínica proveniente de duas fontes heterogéneas — uma base de dados relacional e ficheiros CSV enviados por laboratórios externos.

O processo revelou-se substancialmente mais complexo do que uma simples transferência de dados. A heterogeneidade das fontes manifestou-se a vários níveis: diferenças na estrutura dos dados, com o CSV a agregar numa única linha informação que na BD relacional se encontra distribuída por três tabelas distintas (`Doentes`, `Consultas` e `Análise`); divergências na nomenclatura dos atributos, exigindo um mapeamento explícito entre campos como `n_utente` e `id_doente`, ou `Appointment_date` e `data_consulta`; e a ausência de um identificador de pedido no CSV, tornando necessário estabelecer a correspondência com a BD relacional através da combinação de `n_Appointment`, `Appointment_date` e `id_fonte`. A estes desafios acresce a necessidade de garantir a unicidade global dos registos num sistema multi-fonte, onde o mesmo identificador local pode referir-se a entidades distintas em unidades de saúde diferentes.

Do ponto de vista da modelação, a representação do processo em BPMN revelou-se particularmente útil para estruturar e comunicar a lógica do agente, tornando explícitos os pontos de decisão, os mecanismos de tratamento de erros, como colocar em quarentena, e o fluxo de dados entre as diferentes fases.

Em síntese, os principais contributos do trabalho são:

- A definição de um modelo completo e documentado do agente, cobrindo todas as fases do processo — extração, conciliação, preparação, carregamento e controlo;
- A especificação de um mecanismo de correspondência entre o CSV e a BD relacional baseado na combinação de `n_Appointment`, `Appointment_date` e `id_fonte`, que resolve a ausência de um identificador de pedido explícito no CSV;
- A proposta de uma arquitetura de *staging area* com três camadas de tabelas (intermédias, quarentena e prontas), que isola os erros sem interromper o processamento dos registos válidos;
- A definição de um mecanismo de quarentena com reavaliação automática no ciclo seguinte, que permite recuperar registos inicialmente não conciliáveis sem necessidade de intervenção manual imediata;

Como trabalho futuro, identificam-se as seguintes linhas de desenvolvimento, como a implementação do agente, adicionar mais fontes de dados, monitorização e alertas por mensagem e o processo de integração no *data warehouse.*

Referências

[1] R. Kimball e M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3.ª ed. Wiley, 2013.

[2] R. Kimball, J. Mundy, W. Thornthwaite e B. Becker, *The Data Warehouse Lifecycle Toolkit*, 2.ª ed. Wiley, 2008.

[3] Object Management Group, *Business Process Model and Notation (BPMN), version 2.0.2*. OMG, 2014. [Online]. Disponível em: https://www.omg.org/spec/BPMN/2.0.2

[4] A. Abelló, O. Romero e T. Risch, *Data Warehouse Design: Modern Principles and Methodologies*. Springer, 2015.

[5] M. Kleppmann, *Designing Data-Intensive Applications*. O'Reilly Media, 2017.

[6] P. Vassiliadis, "A survey of Extract–Transform–Load technology," *International Journal of Data Warehousing and Mining*, vol. 5, n.º 3, pp. 1–27, 2009.

[7] E. Rahm e H. H. Do, "Data cleaning: Problems and current approaches," *IEEE Data Engineering Bulletin*, vol. 23, n.º 4, pp. 3–13, 2000.

[8] J. Recker, "Opportunities and constraints: The current struggle with BPMN," *Business Process Management Journal*, vol. 16, n.º 1, pp. 181–201, 2010.

[9] M. Dumas, M. La Rosa, J. Mendling e H. A. Reijers, *Fundamentals of Business Process Management*, 2.ª ed. Springer, 2018.

Lista de Siglas e Acrónimos

BD	Base de Dados
BPMN	*Business Process Model and Notation*
DSA	*Data Staging Area*
DW	*Data Warehouse*
ETL	*Extract, Transform, Load*
GMT	*Greenwich Mean Time*
RGPD	Regulamento Geral sobre a Proteção de Dados
SQL	*Structured Query Language*